

Chapitre I :  
Analyse Descriptive/prédictive :  
Apprentissage Non Supervisé/Supervisé :


**ANALAYSE DISCRIMINANTE : AD**

# Introduction:

- ACP ana

- Elle ch
  - individ

- Par co
  - bonne
  - individ



onnées

es points

ent une  
es des

- L'analyse discriminante cherche des projections qui sont efficaces pour discriminer(distinguer/séparer) les classes.

# AD: Objectif:

- On dispose d'un tableau Individus/Variables **MAIS** les individus sont répartis en un ensemble de classes (groupes) définies selon des variables mesurées sur ses individus.
- L'objectif est de rechercher les combinaisons linéaires de variables :
- Qui permettent de séparer au mieux les différents groupes
  - Maximiser la variance inter classes
  - Minimiser la variance intra classes

# AD: Définition

- L'AD permet d'étudier la différence entre 2 ou plusieurs groupes (pour donner le moyen d'une éventuelle classification) en tenant compte de multiples vars simultanément.
- C'est aussi : étudier les relations entre **une variable qualitative et un ensemble de variable explicatives quantitatives**


# Approches de l'AD:

On distingue deux approches de l'AD

- I. Approche descriptive appelée ADF :Analyse Discriminante de Fisher(Réduction de Dimension)
- II. Approche Prédictive :classification:
  1. Règle géométrique de classification;
  2. Approche Probabiliste simplifiée de Classification.

# I- AD de Fisher Descriptive:

- L'objectif est de créer de nouvelles variables qui sont particulièrement efficaces pour séparer les classe
- Ces vars appel Discriminants » combinaison linéa
- Il faut que la pro discriminant soit (



# I- ADF: Formulation du Problème:


- Y variable à expliquer qualitative à k groupes;
- X1,X2,...Xp P variables explicatives quantitatives
- N nombre d'observations Totale;
- Ni: nombre d'observations du groupe i i=1..k
- G est le centre de gravité des n observations
- Gi est le centre de gravité des observations du groupe i
- $V = W + B$
- W= Matrice de variance intragroupe(within)=  

$$W_{(p \times p)} = \frac{1}{n} \sum_i^k n_i V_i$$
- B= Matrice de variance intergroupe(Between)=


$$B_{(p \times p)} = \frac{1}{n} \sum_i^k n_i (g_i - g)(g_i - g)^t$$

# I- ADF: Résolution du Problème:

- Pour déterminer les axes discriminants il faut:
- Minimiser la Distance intra-classe :  $\min (U^t W U)$
- U: Vecteur unité de l'axe discriminant:



- Maximiser la Distance inter-classe :  $\max \left[ \frac{U^t B U}{U^t V U} \right]$





# I- ADF: Résolution du Problème:

- il faut annuler la dérivée de la fonction pour trouver le Max.
- On va avant remplacer la fonction à maximiser par une fonction avec les multiplicateurs de Lagrange  $\lambda$
- Il faut donc trouver les  $\lambda$  et vecteurs propres :
  - $$\frac{\partial (U^t B U - \lambda (U^t V U^{-1}))}{\partial U} = 0$$
  -
- $2BU - 2\lambda VU = 0$
- $V^{-1}BU = \lambda U$

# I- ADF: Résolution du Problème:

- On recherche l'axe correspondant à la séparation maximale entre les classes →

- $V^{-1}BU = \lambda U$   $0 < \lambda < 1$

$\lambda = 0$  aucune séparation linéaire entre les classes


$\lambda = 1$  : Séparation parfaite entre les classes

$\lambda$  : multiplicateur de lagrange;

U est donc vecteur propre de la matrice  $V^{-1}B$   
correspondant à la plus grande valeur propre.

## ADF: Remarque:

- En général  $n > P > k \rightarrow$  il y a au plus  $(k-1)$  axes factorielles.
- Pour trouver les autres facteurs: Nous avons la projection des points sur le premier axe a une variance inter-classe maximale, le 2eme axe est perpenduculaire au 1<sup>er</sup> et de variance interclasse max....



## II- AD PREDICTIVE :Classification:

### 1-Règle Géométrique

- Nous avons de nouvelles observations qu'on veut classer dans un des groupes:
  - A. Une idée est de calculer la distance entre la nouvelle observation et le centre de chacun des groupes, l'observation est classée dans le groupe pour lequel cette distance est minimale:

$$d^2(x, g_i) = (x - g_i)^t V^{-1} (x - g_i)$$

Ou  $g_i$  est le vecteur (p,1) des moyennes des p variables du groupe i

## II- AD Classification: 1-Règle Géométrique

B. Une deuxième idée est de classer l'observation dans le groupe pour lequel  $f_i$  est maximal avec :

$$f_i = \left( X^t V^{-1} g_i - \frac{1}{2} g_i^t V^{-1} g_i \right) = \left( X^t - \frac{1}{2} g_i^t \right) V^{-1} g_i$$

Les  $f_i$  sont appelées fonctions de classification ou fonctions linéaires discriminantes, On en possède autant qu'il y a des groupes et on affecte la nouvelle obs au groupe pour lequel sa fct de classification est maximale.

## II- AD Classification:

### 2-Approche probabiliste simplifiée:

- L'idée est de classer une observation dans le groupe pour lequel la probabilité conditionnelle d'appartenir à ce groupe est maximale sous l'hypothèse que les observations proviennent d'une loi multinormale (chaque groupe suit une loi normale)

## II- AD Classification:

### 2-Approche probabiliste simplifiée:

- La probabilité qu'une observation appartienne à un groupe est :

$$P(\text{groupe } i / x) = \frac{f_i(x)}{\sum_j^k f_j(x)}$$

- Les  $f_i$  sont les fonctions de classification.
- Cette probabilité est maximale quand  $f_i$  est maximale.

## AD : Remarques:

1. Les approches géométriques et probabilistes sont équivalentes lorsque on a  $k$  populations multinormale avec même matrice de covariance.
2. Si les matrices varient d'un groupe à l'autre, on se trouve à effectuer une discrimination non Linéaire:
  - ➔ Les zones attachées à chaque groupe sont délimitées par des courbes ce qui est une discrimination quadratique (elle est rarement utilisée).



## Exemple :

- Des ménages selon le nombre d'enfants(2,3,4,5) statut socio-professionnel(Cadre, Employé et Manuel) et la consommation en viandes volaille, legumes fruits et boissons....
- Le facteur de taille mis en évidence est lié à la taille du ménage et à son statut sociau-professionnel, ce qui implique la dépense globale qui augmente avec le nbre d'enfants et le statut social

# Conclusion

- L'analyse discriminante permet de réduire la dimensionnalité des problèmes
  - Pour l'apprentissage paramétrique, elle permet de réduire le nombre de paramètres à estimer(Réduction de Dimension)
  - Et Beaucoup dans la reconnaissance des formes(Classification)