

Chapitre II : Analyse Prédictive : (Prédire une Catégorie : Classification)

II- 3- Classification Linéaire : Régression Logistique


PLAQUETE COMMERCIALE



Régression Linéaire Simple:

Input features

Output




$$y = a_0 + a_1x$$

Equation d'une Droite

Régression Linéaire Multiple/Polynomiale:


Input features



$$Y = a_0 h_0(x) + a_1 h_1(x) + a_2 h_2(x) + \dots + a_p h_p(x)$$

Régression Logistique

Input features



- Cette approche de prévision utilise la même forme linéaire que celle utilisée pour la régression.
- Au lieu de prédire une valeur cible continue, nous prenons la sortie de la fonction linéaire et appliquons la fonction **Sigmoid** pour produire une sortie binaire avec deux valeurs possibles (2 étiquettes de classe possibles).
- Si la valeur cible $> 0,5$, \rightarrow la fonction renvoie +1
- si la valeur cible $< 0,5$ \rightarrow la fonction renvoie -1

La Régression Logistique:

La régression logistique est un modèle de classification linéaire simple ou nous avons deux variables Y et X :

Y est la variable expliquée qualitative et X est la variable explicative , seulement ici X est donnée avec plusieurs features , elle peut être quantitative ou qualitative(On doit codifier)


Codage des catégories ou des classes :

Si les entrées sont quantitatives (numériques) Longueur, Largeur...pas de problème de multiplication,

mais si les entrées sont qualitatives, alors on procède a une codification des entrées.

Régression Logistique

Input features



On reprend la formule générale de la régression depuis le chapitre II Regression polynomiale :

$$Y = a_0 h_0(x) + a_1 h_1(x) + a_2 h_2(x) + a_3 h_3(x) + \dots + a_p h_p(x) = a^T H(x)$$

Sachant que :

$h_0(x) = \text{feature0}$;

$h_1(x) = \text{feature1}$;

.....

$h_n(x) = \text{feature } n$

Le modèle de la régression Logistique :

Donc : $Y' = f(Y) = f(a^T H(x))$

$$Y' = f(a_0 h_0(x) + a_1 h_1(x) + a_2 h_2(x) + a_3 h_3(x) + \dots + a_p(h_p(x)))$$

La fonction 'f' s'appelle : Fonction Logistique:

$$Y' = \text{logistic}[a_0 h_0(x) + a_1 h_1(x) + a_2 h_2(x) + a_3 h_3(x) + \dots + a_p(h_p(x))]$$

La fonction logistique transforme une entrée réelle en une probabilité que la classe soit positive.

$$Y' = P(Y = +1/X) = f(a^T H(x))$$

Le modèle de la régression Logistique :

$$Y' = P(Y=+1/X) = f(a^T H(x_i))$$

→ SI $P(Y=+1/X) \geq 0.5$ (ou $a^T H(x_i) > 0$) Alors

$$y'(x_i) = +1$$

Sinon

$$y'(x_i) = -1 \text{ ou } 0$$

La fonction Logistique/Sigmoid


Dans notre cas :
g est la fonction f

ar :

Dans notre cas :
Score = $a^T H(x)$

$$g(\text{score}) = \text{sigmoid}(\text{score}) = \frac{1}{1 + e^{-\text{Score}}}$$

Elle prend ses valeurs entre 0 et 1 :



Score	$-\infty$	0.	$+\infty$
Sigmoid(score)	0	0.5	1

Dans la régression logistique,

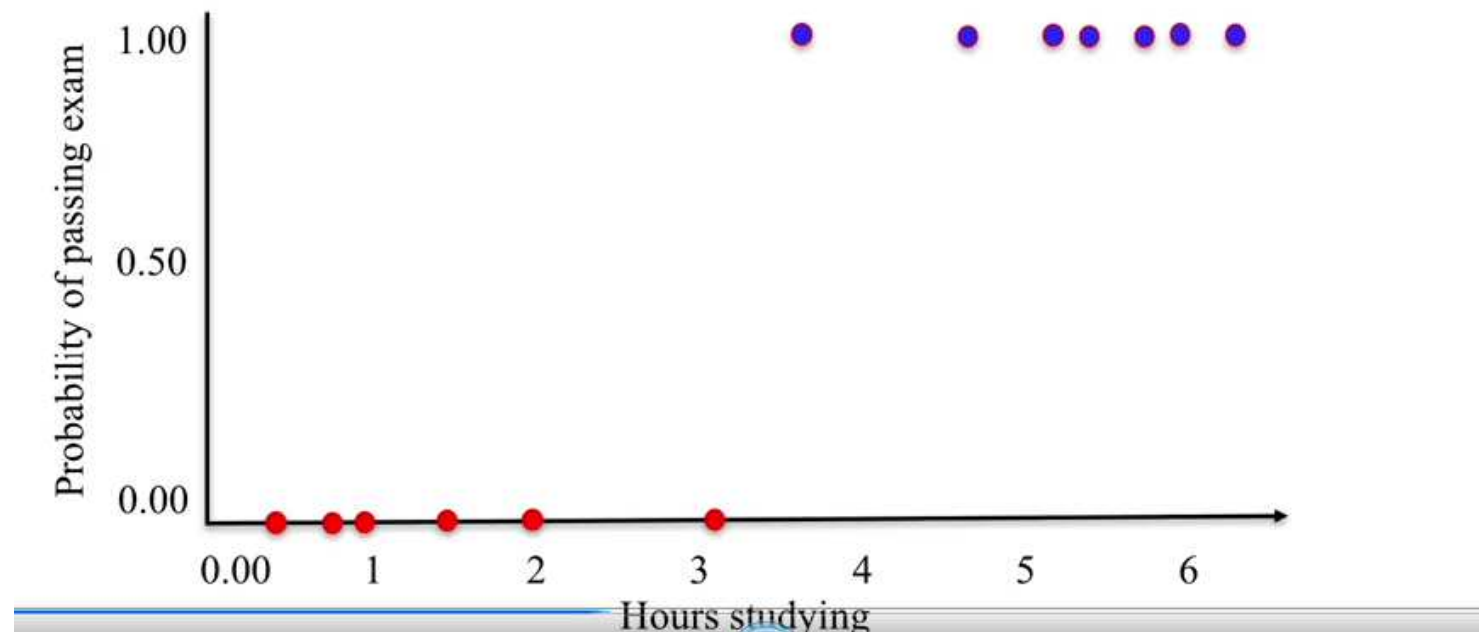
- On ne prédit pas +1 ou -1.
- Nous prédisons une probabilité.

Quelle est la probabilité que cette évaluation soit positive?

Quelle est la probabilité d'être négatif?


Régression Logistique: Classification avec Un seul Feature

Linear models for classification: Logistic Regression



- On dispose d'une seule variable Heures d'étude, et on voudrait classer les étudiants selon cette variable pour savoir qui va réussir /Non
- On donne les probabilités pour chacun selon nbre Heures.

Linear models for classification: Logistic Regression



En utilisant la Régression Logistique on estime les coefficients du modèle qui s'ajuste au mieux à l'ensemble des points


Probabilité $> 0.5 \rightarrow Y(\text{classe}=+1)$

Probabilité $< 0.5 \rightarrow Y(\text{classe}=0 \text{ ou } -1)$



\rightarrow Les étudiants qui étudient plus de 3h passent l'examen,
sinon Non

Régression Logistique :

Classification avec deux Features:




Régression Logistique : Classification avec deux Features:



Autrement dit: La Régression Logistique donne une limite de décision linéaire entre les deux classes ici un plan (Deux Features).

Les classifieurs non linéaire : la limite de décision possède des formes plus complexes :

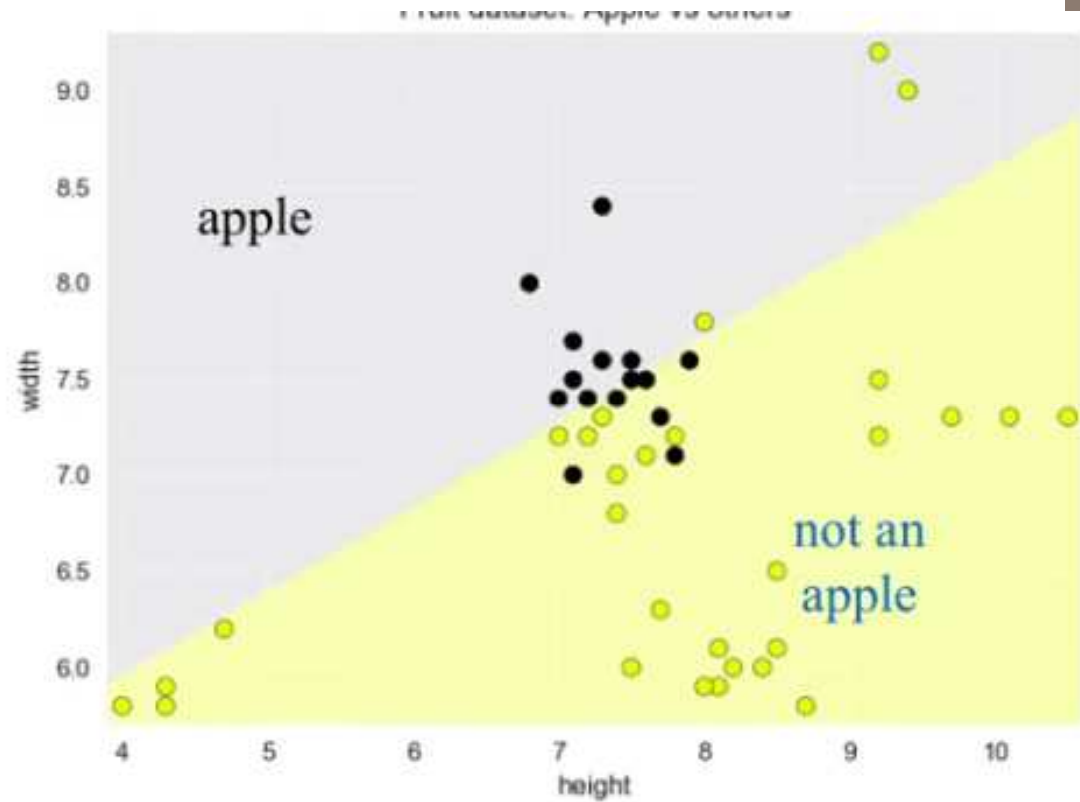
L



Régression Logistique Simple :

Classification de Fruits Pomme Vs Autre:

Fruits	Largeur	Hauteur
Pomme	7	5
Orange	9	6
Lemon	11	4
Mandarine	4	3
Pomme	8	6
.....		




Un classifieur linéaire doit utiliser les données d'apprentissage pour apprendre ou calculer les coefficients ou les poids de chaque feature (Largeur, Hauteur).

Trouver le meilleur classifieur :

Pour trouver le meilleur classifieur, on doit **maximiser** la qualité de la métrique appelée « Likelyhood = Vraisemblance »

l(a).par rapport a tous les a0,a1,a2...



Trouver le Meilleur classifieur :

La qualité de la métrique
« Likelyhood = Vraisemblance »

$$l(a) = \prod_{i=1}^N P(y_i | \mathbf{x}_i, a)$$

Nous avons:

$$Y' = P(Y=+1/X) = f(a^T H(x_i)) \rightarrow$$


$$l(a) = \prod_{i=1}^N g(a^T H(x_i))$$

Meilleur classifieur = Maximiser $l(a)$

$L(a)$ = fonction +eurs variables a_0, a_1, \dots, a_D

→ Utiliser un Algorithme d'Optimisation

→ tel que Ascent Gradient



l'Algorithme Ascent Gradient :

Début

$t=1$

Initialiser les coefficients (a);

*Initialiser ε :tolérance ;

Initialiser : η le 'pas' ;

While (not converged)

$a(t+1) \leftarrow a_t + \eta \text{grad}(l(a))$

$t \leftarrow t+1$

Fin

Apprentissage de l'algo AscG pour la régression logistique:



Réalité



Prédiction

$$\frac{\partial l(a)}{\partial a_j} = \sum_{i=1}^n h_j(x_i) (v[y_i = +1] - p(y_i = +1/x_i, a))$$

Différence entre la réalité et la prédiction


$v[y_i = +1]$

est appelé indicateur de la fonction = 1 si $y_i = +1$
=0 sinon

Multi classes Classification :

(L'approche : une classe versus toutes les classes):


On voudrait classer une image ou un objet dans l'image , par exemple :







Est-ce qu'il s'agit d'une oie d'un chien, d'une camera.....

Formulation :

Nous avons C classes de formes : →
y peut être 1,2,...,C



Data point	x[1]	x[2]	y
x_1, y_1	2	1	
x_2, y_2	0	2	
x_3, y_3	3	3	
x_4, y_4	4	1	

Nous avons N points de données. Et on voudrait apprendre :

$$\begin{aligned} \hat{P}(y=\triangle | x) \\ \hat{P}(y=\heartsuit | x) \\ \hat{P}(y=\bigcirc | x) \end{aligned}$$

L'approche « 1 versus All(tout) »: (1 contre tous)


Cette approche Estime:

-- $P(y=\text{triangle}/x)$ en utilisant le modèle de 2 classes.


➔ +1 : Classe avec ($y_i=\text{triangle}$)

➔ -1 : Classe avec ($y_i=\text{cercle}$ ou $y_i=\text{coeur}$)


$$\hat{P}(y=\triangle | x_i) = \hat{P}_\triangle(y=\triangle | x_i, w)$$



$$\hat{P}(y=\heartsuit | x_i) = \hat{P}_\heartsuit(y=\heartsuit | x_i, w)$$



$$\hat{P}(y=\circ | x_i) = \hat{P}_\circ(y=\circ | x_i, w)$$



- Ensuite on assignera x_i a la classe qui a la plus grande probabilité.
- On aura donc 3 classifieurs logistiques
Simple == **Au Nombre de Classes.**

En général, l'algorithme de la Multiclassification est le suivant :

Début

max_prob= 0;

$\hat{Y} = 0$

For $c=1,\dots,C$:

if $\hat{P}_c = (y = +1|X_i) > \text{max_prob}$:

$\hat{Y} = c$

max_prob = $\hat{P}_c = (y = +1|X_i)$

Fin.

Quiz Regression Logistique:

La Regression Logistique est un
classifieur Non Linéaire

V F

La Régression Logistique **est** une
Régression Linéaire

V F

**Dans La Régression Logistique la
variable explicative X peut être
qualitative**

V F

Quelle est la fonction qui compresse
la valeur réelle en $[0, 1]$?

1-Logistic function

2-Absolute value function

3-Zero Function

Si $aT.h(\mathbf{x}) > 0$, qu'est ce qui est vrai pour $P(y=+1 | \mathbf{x})$?

1- $P(y = +1 | x) < 0.5$

2- $P(y = +1 | x) \geq 0.5$

3- on peut rien dire concer nant $P(y = +1 | x)$

L'algorithme Descente de Gradient est utilisé pour trouver la meilleure séparation entre classes.

V **F**

La Regression Logistique est un
classifieur Binaire

V F

Vous Envisagez de former un classificateur multiclasse « 1 contre tous » pour le problème de la reconnaissance des chiffres à l'aide de la régression logistique.

On utilise la base données DIGIT qui contient les chiffres de 0 à 9.

Combien de classificateurs de régression logistique devons-nous former ?

l'algorithme Ascent Gradient :

Début

Initialiser $a(1)=0$ (ou bien aléatoirement ou bien intelligemment)

Initialiser ε :tolérance

Initialiser : η le 'pas'

While $\|\text{grad}(l(a(t)))\| > \varepsilon$ (not converged)

For $j=0..D$

$\text{Partial}[j] = \sum_{i=1}^n h_j(x_i)(v[y_i = +1] - p(y_i = +1|x_i, a))$

$a_j(t+1) \leftarrow a_j(t) + \eta \text{partial}[j]$

$t \leftarrow t+1$

Fin

Partial[j] est la dérivée de $l(a)$ par rapport à a_j ,

Elle est définie comme suit :

$$\nabla l(a) = \left(\frac{\partial l(a)}{\partial a_0}, \frac{\partial l(a)}{\partial a_j}, \dots \right)$$

$$\left[\frac{\partial l(a)}{\partial a_j} \right] = \sum_{i=1}^n h_j(x_i) (v[y_i = +1] - p(y_i = +1/x_i, a))$$

Différence entre la réalité et la prédiction

$v[y_i = +1]$ est appelé indicateur de la fonction = 1 si $y_i = +1$

= 0 sinon

Apprentissage de l'algo AscG pour la régression logistique:

$$\frac{\partial l(w)}{\partial w_j} = \sum_{i=1}^n h_j(x_i) (v[y_i = +1] - p(y_i = +1 | x_i, w))$$

Différence entre la réalité et la prédiction

cette derivative pousse les coefficients à augmenter si $y_i = +1$ si les exemples d'apprentissage positifs

Et à diminuer si $y_i = -1$ si les exemples d'apprentissage négatifs